

Ноутбук служит основой для изучения, однако многое нужно будет поискать и почитать самостоятельно

Част ь 1: теория (5 pt)

Данные

В реальной практике **80% времени уходит на анализ и подготовку данных**, а не на построение моделей или визуализацию. Грязные данные ведут к ошибочным выводам:

Проблема	Последствие для анализа
Пропуски	Смещение средних значений, потеря наблюдений
Дубликаты	Завышенные частоты, искажённая статистика
Аномалии	Искажение корреляций, неработающие модели МО
Несогласованный текст	Невозможность группировки по категориям

В этой части поработаем именно с этими четырьмя пунктами. Однако во второй части вы можете использовать любые известные вам методы.

Чтобы изменить содержимое ячейки, дважды нажмите на нее (или выберите "Ввод")

```
import pandas as pd
import seaborn as sns
import numpy as np

# Вот так можно смотреть версию (некоторые методы зависят от версии)
print(f"Pandas version: {pd.__version__}")
```

Pandas version: 2.2.2

Мы начнём с [датасета](#) — **Wine Reviews**. Этот датасет как раз подойдет нам для обсуждения методов.

В описании датасета можно прочитать описание столбцов и их значение.

```
from google.colab import files
uploaded = files.upload()
wine = pd.read_csv('winemag-data-130k-v2.csv')
print(wine.shape)
print(wine.columns.tolist())
```

Выбрать файлы winemag-...0k-v2.csv
winemag-data-130k-v2.csv(text/csv) - 52908706 bytes, last modified: 06.03.2026 - 100% done
Saving winemag-data-130k-v2.csv to winemag-data-130k-v2.csv
(129971, 14)
['Unnamed: 0', 'country', 'description', 'designation', 'points', 'price', 'province', 'region_1', 'region_2', 'taster_name', 'taster_twitter_handle']

```
wine.head(3)
```

Unnamed: 0	country	description	designation	points	price	province	region_1	region_2	taster_name	taster_twitter_handle	
0	0	Italy	Aromas include tropical fruit, broom, brimston...	Vulkà Bianco	87	NaN	Sicily & Sardinia	Etna	NaN	Kerin O'Keefe	@kerinok
1	1	Portugal	This is ripe and fruity, a wine that is smooth...	Avidagos	87	15.0	Douro	NaN	NaN	Roger Voss	@vossn
2	2	US	Tart and snappy, the flavors of lime flesh and...	NaN	87	14.0	Oregon	Willamette Valley	Willamette Valley	Paul Gregutt	@paulg

Видно, что датасет считался некорректно и у нас появился столбец `Unnamed: 0`. Это произошло потому что pandas автоматически присваивает индексы, но в нашем датасете первый столбец уже был индексами. Это можно исправить с помощью чтения с параметром

```
wine = pd.read_csv('winemag-data-130k-v2.csv', index_col=0)
```

Но мы пойдем другим способом и просто **удалим** этот столбец с помощью метода `.drop()`

```
wine = wine.drop(columns=['Unnamed: 0'])
```

Также для того, чтобы нам было проще работать в этом задании удалим еще некоторые столбцы. То есть **оставим** только те, которые нам интересны.

```
wine = wine[['country', 'description', 'winery', 'designation', 'points', 'price', 'province', 'title', 'variety']]
```

```
wine.head()
```

	country	description	winery	designation	points	price	province	title	variety
0	Italy	Aromas include tropical fruit, broom, brimston...	Nicosia	Vulkà Bianco	87	NaN	Sicily & Sardinia	Nicosia 2013 Vulkà Bianco (Etna)	White Blend
1	Portugal	This is ripe and fruity, a wine that is smooth...	Quinta dos Avidagos	Avidagos	87	15.0	Douro	Quinta dos Avidagos 2011 Avidagos Red (Douro)	Portuguese Red
2	US	Tart and snappy, the flavors of lime flesh and...	Rainstorm	NaN	87	14.0	Oregon	Rainstorm 2013 Pinot Gris (Willamette Valley)	Pinot Gris
3	US	Pineapple rind, lemon pith and orange	St. Julian	Reserve Late Harvest	87	13.0	Michigan	St. Julian 2013 Reserve Late	Riesling

✓ Диагностика проблем (1 pt)

Перед любыми действиями нужно **понять, какие проблемы есть в данных**. Базовый чек-лист:

Проблема	Метод диагностики	Что ищем
Пропуски	<code>.isna().sum()</code>	Количество <code>NaN</code> по столбцам
Дубликаты	<code>.duplicated().sum()</code>	Полные или частичные повторы строк
Аномалии	<code>.describe()</code> + визуализация	Значения за пределами ожидаемого диапазона
Несоответствующий текст	<code>.value_counts()</code>	Опечатки, разный регистр, лишние пробелы

Сууждения об аномалиях можно делать на основе жизненной (бизнес) логики (не может кот весить тонну) и/или странных сочетаний `min`, `mean`, `max` и других статистик.

В репорте `value_counts` видно, сколько раз повторяется значение. Поэтому если строковое значение повторяется только один раз (хотя при это, например, категория), то стоит задуматься о том, что нужно данные как-то преобразовать.

Про некоторые методы вы уже знаете, а про остальные можно посмотреть в документации: [pandas.DataFrame.isna](#), [pandas.DataFrame.duplicated](#).

Предположим, что мы совсем не разбираемся в вине (надеюсь, что вам и предполагать не надо) и хотим что-то про него понять. Например какое и за сколько лучше всего.

```
# ЗАДАНИЕ:
# 1. Посчитайте количество пропусков (NaN) по каждому столбцу
# 2. Найдите количество полных дубликатов строк
# 3. Выведите базовую статистику для числовых столбцов
# 4. Проанализируйте распределение цены – есть ли подозрительные значения?
# 5. Напишите небольшой вывод о водможных проблемах с данными

print('Пропуски по столбцам:\n', wine.isna().sum())

print('\n Кол-во дубликатов:\n', wine.duplicated().sum())

print("\n Базовая статистика:\n", wine.describe())

print(wine['price'].head(5)) #смотрим первые 5 значений
print(wine['price'].sort_values(ascending=False).head(5)) #смотрим максимальные 5 значений
print(wine['price'].sort_values(ascending=True).head(5)) #смотрим минимальные 5 значений
wine['price'].sample(5, random_state=42) #метод чтобы посмотреть случайные 5 значений
```

```

Пропуски по столбцам:
country      63
description  0
winery       0
designation  37465
points       0
price        8996
province     63
title        0
variety      1
dtype: int64

Кол-во дубликатов:
9983

Базовая статистика:
              points      price
count  129971.000000  120975.000000
mean      88.447138    35.363389
std       3.039730    41.022218
min       80.000000     4.000000
25%       86.000000    17.000000
50%       88.000000    25.000000
75%       91.000000    42.000000
max       100.000000   3300.000000
0         NaN
1         15.0
2         14.0
3         13.0
4         65.0
Name: price, dtype: float64
80290      3300.0
98380      2500.0
15840      2500.0
120391     2013.0
65352      2000.0
Name: price, dtype: float64
1987        4.0
126096      4.0
59507       4.0
110255      4.0
29553       4.0
Name: price, dtype: float64

```

	price
77718	5.0
67681	12.0
69877	9.0
46544	29.0
186	40.0

```

dtype: float64

```

Сначала посмотрим на распределение цен. Из базовой статистики видно, что значение стандартного отклонения большое. Это очевидно и если посмотреть на медиану. Медиана равно 25, при этом max = 3300, это явно выброс. Среднее анализировать смысла нет, потому что оно не устойчиво к выбросам. Далее я решила посмотреть, какие вообще есть значения в колонке цен. Минимум и максимум особо ничего не дал, потому что минимальные 5 значений равны четырем, а максимальные похожи на выбросы, поэтому я дополнительно посмотрела первые 5 значений неотсортированных, и рандомные 5. Из них видно, что все значения в основном до 100, что соответствует и медиане, и квантилям. А также помимо выбросов, "price" содержит 8996 пропусков, что также усложняет работу с этим столбцом. Если говорить про пропуски в целом, то:

Столбец	Количество пропусков
country	63
designation	37465
price	8996
province	63
variety	1

Из-за большого кол-ва пропусков в некоторых столбцах с соответствующими столбцами будет работать сложно.

► Когда будете готовы, кликните сюда, чтобы посмотреть краткую сводку

▼ Обработка дубликатов (0,5 pt)

```
wine.duplicated().sum()
```

```
np.int64(9983)
```

Дубликаты — это полные или частичные повторы строк, которые искажают статистику. В датасете вин есть 9 983 дубликата. Такие повторы будут портить нам статистику, поэтому их лучше удалить. Поможет в этом [.drop_duplicates\(\)](#).

```
# ЗАДАНИЕ: Удалите дубликаты, оставив только первую запись
wine = wine.drop_duplicates()
```

```
wine.duplicated().sum()
```

```
np.int64(0)
```

✓ Обработка пропусков (1 pt)

Выбор стратегии работы с пропусками зависит от **природы пропуска**. Например для цены нам критично заполнение пропусков, а вот в столбце `designation` (виноградник на территории винодельни, откуда собирают виноград, из которого делают вино) пропуски для нас не критичны и мы можем заменить их на нейтральное значение нужного типа (`str` "Undefined").

Прочитать про то, как можно работать с пропусками можно много где, например, [тут](#) и [здесь](#).

Главное при заполнении пропусков следовать логике и делать так, чтобы стратегия заполнения не ломала данные. Например можно заполнять пропуски **средним (или наиболее частым) значением по какому-то условию**. Если пропусков мало или они не значимы, то можно удалять такие строки.

Иногда важно смотреть внимательно: не всегда пропуски видны, иногда вместо `NaN` значения содержат нули или неопределенные слова. Такие случаи тоже можно считать пропусками, но в этом датасете такого нет.

Сейчас мы не будем сильно заморачиваться с этим и просто попробуем разные методы:

- в столбце `country` заменим пропуски на наиболее часто встречаемую страну (пропусков не так много, чтобы они повлияли, да и если страна неизвестна, то с очень большой вероятностью это Италия или Франция)
- В столбце `designation` заменим пропуски на метку "Undefined". Это нормально, что для массовых вин никого не заботит виноградник. Но для того, чтобы мы корректно могли работать со строками заменим наны на строку.
- В столбце `price` заменим пропуски **медианой** по стране. Медианой, а не средним для того, чтобы не влияли выбросы и не появлялись дробные значения.
- В столбце `province` заполним пропуски **модой** по стране (наиболее частым).
- Строку с пропуском в столбце `variety` просто **удалим**

Для начала сделаем **копию датасета** для того, чтобы не потерять изначальные данные!

Вам помогут: [.fillna\(\)](#), [.transform\(\)](#), [.dropna\(\)](#).

```
wine.isna().sum()
```

	0
country	59
description	0
winery	0
designation	34545
points	0
price	8395
province	59
title	0
variety	1

```
dtype: int64
```

```
wine_clean = wine.copy()
```

```
# ЗАДАНИЕ: обработайте пропуски согласно пунктам выше
```

```
most_common_country = wine_clean['country'].mode()[0]
wine_clean['country'] = wine_clean['country'].fillna(most_common_country)

wine_clean['designation'] = wine_clean['designation'].fillna('Undefined')
```

```
country_median_price = wine_clean.groupby('country')['price'].transform(lambda x: x.median())
wine_clean['price'] = wine_clean['price'].fillna(country_median_price)

country_mode_province = wine_clean.groupby('country')['province'].transform(lambda x: x.mode()[0])
wine_clean['province'] = wine_clean['province'].fillna(country_mode_province)

wine_clean = wine_clean.dropna(subset=['variety'])
```

```
# Должно быть по нулям
print(wine_clean.isna().sum())
print("Мы видим, что в price все равно остался один пропуск. Вероятно, это произошло потому, что в каких-то странах нет знач
```

```
country      0
description  0
winery       0
designation  0
points       0
price        1
province     0
title        0
variety      0
dtype: int64
Мы видим, что в price все равно остался один пропуск. Вероятно, это произошло потому, что в каких-то странах нет значений, и
```

Обработка аномалий (0,5 pt)

Аномалии (выбросы) — это значения, которые **значительно отклоняются** от остальных наблюдений. Они могут быть:

- **Ошибка измерения/ввода** (цена вина отрицательна) -> удалить
- **Редкое, но валидное наблюдение** (винтажное вино за много денег) -> сохранить или обработать отдельно
- **Систематическое искажение** (группировка значений на границах) -> исследовать источник

Можно выделить три подхода для обнаружения аномалий или подбора порогов

Подход	Как работает	Плюсы
Бизнес-логика	Определение границ на основе экспертных знаний предметной области	Интерпретируемо, учитывает контекст, не требует сложных вычислений
Статистика (IQR)	Границы: $Q1 - 1.5 \times IQR$ и $Q3 + 1.5 \times IQR$, где $IQR = Q3 - Q1$	Автоматизируемо, не зависит от распределения
Статистика (Z-score)	Границы: $ z > 3$, где $z = (x - \mu) / \sigma$	Хорошо работает для нормальных распределений

Вот тут есть [гайд](#) про то, как определять выбросы.

Также для этого поможет документация: [.quantile\(\)](#), [scipy.stats.zscore](#).

Что же делать с аномалиями?

Стратегия	Когда применять	Пример
Удаление	Аномалия — явная ошибка (цена $\leq$ \$0)	<code>df = df[df['price'] > 0]</code>
Ограничение (capping)	Аномалия — экстремум, но не ошибка	<code>df['price'] = df['price'].clip(upper=500)</code>
Сегментация	Аномалии образуют отдельный сегмент	<code>df['segment'] = pd.cut(df['price'], bins=[0, 50, 100, float('inf')])</code>
Сохранение с пометкой	Нужно анализировать аномалии отдельно	<code>df['is_outlier'] = df['price'] > 500</code>

Кажется, что в нашем случае лучшим решением будет **поделить вина на категории**: дешевые, нормальные, очень дорогие. Для того, чтобы лучше понять данные посмотрим на **диаграмму цен** ([DataFrame.plot.hist](#))

```
wine_clean['price'].plot.hist(bins=100, log=True) #если оставить значение по умолчанию (10), то гистограмма будет ненаглядн
```

<Axes: ylabel='Frequency'>

Какие пороги для ценовых категорий стоит поставить?

Проанализируем гистограмму: имеем много значений около нуля, либо это категория очень дешевых вин, либо это аномалия. Далее умеренное кол-во вин до 500 долларов, а после наблюдается спад в диапазоне от 500 до 1000, однако есть выбросы. После 1000 либо идет категория дорогих вин, либо это выбросы. Смотрим на «массовый сегмент» и редкие выбросы:

Cheap (дешевое) – большинство массовых вин до медианы (25\$)

Medium (среднее) – до верхнего квартиля (50\$)

Expensive (дорогое) – 50–200\$ (премиум, но ещё не супердорогое)

Elite (элитное) – >200\$ (редкие дорогие вина, выбросы на гистограмме)

```
# ЗАДАНИЕ: 1. Создать новый столбец wine_clean['price_category']
#           2. Согласно выявленным порогам определить ценовую категорию каждого вина

bins = [0, 25, 50, 200, float('inf')]
labels = ['cheap', 'medium', 'expensive', 'elite']

wine_clean['price_category'] = pd.cut(wine_clean['price'], bins=bins, labels=labels)
```

```
wine_clean['price_category'].value_counts()
```

	count
price_category	
cheap	62120
medium	39386
expensive	17815
elite	665

dtype: int64

У меня вопрос: я немного не поняла, то, что мы разбили на категории, это и есть "устранение аномалий"? Потому что, кажется, сильно дорогие вина все-таки могут быть выбросами. Хотя я не разбираюсь в винах, может и есть там какие-то супер дорогие. Есть еще гипотеза, что при дальнейшей работе с данными и статистикой по ним мы как раз и будем смотреть на отдельные категории по ценам, тогда такой разброс цен и даже выбросы нам не сильно мешают. С этой точки зрения уже похоже на работу с аномалиями.

✓ Обработка текста (0,5 pt)

Текстовые данные в реальных датасетах часто содержат **несогласованные обозначения**, которые мешают корректной группировке и анализу. Например могут быть следующие проблемы:

Столбец	Проблема	Примеры из данных
country	Разные форматы для одной страны	'US', 'USA', 'U.S.A.', 'United States'
province	Разный регистр и лишние пробелы	'california ', 'California', 'CALIFORNIA'
variety	Опечатки и синонимы	'Pinot Noir' vs 'PinotNoir'

Нам повезло, в нашем датасете такого нет, однако, встретиться такое может часто.

Как приводить текстовые/категориальные данные в общий вид?

Метод	Назначение	Пример
<code>.str.strip()</code>	Удаляет пробелы по краям	' California ' → 'California'
<code>.str.lower()</code> / <code>.str.title()</code>	Приводит к единому регистру	'california' → 'California'
<code>.replace()</code>	Заменяет значения по словарю	{'US': 'United States'}
<code>.str.contains()</code>	Поиск подстроки (регистронезависимый)	<code>contains('berry', case=False)</code>

Как всегда подробнее в документации: [.str.strip\(\)](#), [.str.lower\(\)](#), [.replace\(\)](#), [.str.contains\(\)](#).

```
# Проверьте, что в нашем датасете нет таких проблем

# проверим самые частые значения
print(wine_clean['country'].value_counts().head(10))
print(wine_clean['province'].value_counts().head(10))
print(wine_clean['variety'].value_counts().head(10))
```

```

country
US          50516
France      20353
Italy       17940
Spain       6116
Portugal    5256
Chile       4183
Argentina   3544
Austria     3034
Australia   2197
Germany     1992
Name: count, dtype: int64
province
California   33715
Washington   7965
Bordeaux     5556
Tuscany      5391
Oregon       4929
Burgundy     3683
Northern Spain 3554
Piedmont     3441
Mendoza Province 3038
Veneto       2501
Name: count, dtype: int64
variety
Pinot Noir      12278
Chardonnay      10868
Cabernet Sauvignon 8840
Red Blend       8243
Bordeaux-style Red Blend 6471
Riesling        4773
Sauvignon Blanc 4575
Syrah           3828
Rosé            3220
Merlot          2896
Name: count, dtype: int64

```

этого не совсем достаточно для проверки того, что все корректно, тут нет проверки на пробелы, но это пишется отдельно для каждого столбца. мне кажется такие ошибки проверяются или обнаруживаются уже на каком-то из этапов работы с данными.

Что касается текстовых данных, то у нас есть очень информативный столбец `description`, из которого можно вытащить много информации. Для того, чтобы это было сделать легче, приведем все буквы к строчному виду и удалим знаки препинания.

```

# ЗАДАНИЕ: приведите описания к нижнему регистру и удалите знаки препинания
wine_clean['description'].head(10) #посмотреть как столбец выглядит сейчас
wine_clean['description'] = (wine_clean['description'].str.lower().str.replace(r'[^\w\s]', '', regex=True)) # '[^\w\s] уда

```

```
wine_clean.description[42]
```

```
'this is a festive wine with soft ripe fruit and acidity plus a red berry flavor'
```

✓ Вывод (1,5 pt)

Теперь по подготовленным данным ответьте на следующие вопросы (**напишите код и небольшие выводы**):

- Какая страна производит самые дорогие вина (по средней цене)? Какая — самые дешёвые? Какие страны производят очень дорогие вина?
- Есть ли связь между ценой и рейтингом? Вина какой ценовой категории получают самый высокий средний рейтинг?
- Какие 3 сорта винограда (variety) самые лучшие (по цене, по рейтингу)?
- Сравните средний рейтинг разных ценовых сегментов. Насколько отличается качество между бюджетным и премиум-сегментом?
- В каких ценовых сегментах встречаются фруктовые вина (посмотрите вхождения ключевых слов в описания)?

```

# Средняя цена по странам
country_price = wine_clean.groupby('country')['price'].mean().sort_values(ascending=False)
print(country_price.head(5)) # топ 5 дорогих стран
print(country_price.tail(5)) # топ 5 дешёвых стран

```

```

country
Switzerland  72.833333
England      52.507937
Germany      43.121988
Hungary      42.100775
France       38.598290
Name: price, dtype: float64

```

```
country
Armenia          14.500000
India            13.750000
Bosnia and Herzegovina 12.500000
Ukraine          9.214286
Egypt            NaN
Name: price, dtype: float64
```

```
#топ три сорта винограда по среднему рейтингу
wine_clean.groupby('variety')['points'].mean().sort_values(ascending=False).head(3)
```

```

           points
variety
Tinta del Pais    95.0
Terrantez         95.0
Gelber Traminer   95.0
```

```
dtype: float64
```

```
# Средний рейтинг по ценовой категории
wine_clean.groupby('price_category')['points'].mean()
```

```
/tmp/ipykernel_688/3269901985.py:2: FutureWarning: The default of observed=False is deprecated and will be changed to True i
wine_clean.groupby('price_category')['points'].mean()
```

```

           points
price_category
cheap          87.081391
medium         89.195679
expensive      91.300253
elite          94.381955
```

```
dtype: float64
```

```
#топ три сорта винограда по средней цене
wine_clean.groupby('variety')['price'].mean().sort_values(ascending=False).head(3)
```

```

           price
variety
Ramisco    495.0
Terrantez  236.0
Francisa   160.0
```

```
dtype: float64
```

```
# создаём булев столбец, True если описание содержит фруктовые слова
fruit_keywords = 'berry|cherry|fruit|apple|citrus|peach'
```

```
wine_clean['is_fruity'] = wine_clean['description'].str.contains(fruit_keywords, case=False, regex=True)
wine_clean.groupby('price_category')['is_fruity'].sum()
wine_clean.groupby('price_category')['is_fruity'].mean() * 100
```

```
/tmp/ipykernel_688/2326598717.py:5: FutureWarning: The default of observed=False is deprecated and will be changed to True i
wine_clean.groupby('price_category')['is_fruity'].sum()
```

```
/tmp/ipykernel_688/2326598717.py:6: FutureWarning: The default of observed=False is deprecated and will be changed to True i
wine_clean.groupby('price_category')['is_fruity'].mean() * 100
```

```

           is_fruity
price_category
cheap          86.162267
medium         84.933733
expensive      84.282908
elite          84.060150
```

```
dtype: float64
```


Вывод:

Топ 5 самых дорогих стран (по среднему значению):

Страна	Средняя цена
Switzerland	72.83
England	52.51
Germany	43.12
Hungary	42.10
France	38.60

Топ 5 самых дешевых стран (по среднему значению):

Страна	Средняя цена
Armenia	14.50
India	13.75
Bosnia and Herzegovina	12.50
Ukraine	9.21
Egypt	NaN

Здесь у Египта "NaN" потому что, когда мы удаляли пропуски и заполняли их медианой, видимо, у Египта изначально все данные по цене были NaN.

Связь между рейтингом и ценовой категорией есть. Самая элитная категория имеет средний рейтинг 94, и в целом рейтинг возрастает в соответствии с ценовым сегментом, что довольно логично. Также интересно то, что категория самых дешевых вин имеет довольно большой средний рейтинг - 87. Таким образом элитные вина по рейтингу отличаются от дешевых в среднем всего на 7 баллов.

✓ Часть 2: практика (5 pt)

В этой части вам нужно самостоятельно провести анализ датасета и сделать выводы.

ЗАДАНИЕ: подготовить данные и сделать три неочевидных/интересных вывода (основывающихся на данных)

В качестве датасета возьмем данные [Netflix](#).

Оцениваться будут следующие пункты:

- Диагностика проблем (1 pt)
- Подготовка и очистка данных, в том числе добавление новых столбцов, выделение категорий и тд. Важна аргументация и пояснения выбора методов. (2 pt)
- Анализ данных и выводы (2 pt)

В качестве отправной точки можете использовать вопросы:

- Какие 3 страны производят больше всего контента для Netflix? Есть ли различия между фильмами и сериалами?
- В каком году было выпущено максимальное количество сериалов?
- Какой возрастной рейтинг самый распространённый для фильмов? Для сериалов? Есть ли страна, где доминируют контент со взрослым рейтингом?
- Какова медианная продолжительность фильмов (в минутах)? Сериалов (в сезонах)?
- Какой жанр доминирует в США? В Индии?
- Какой тип контента «старше»?

Пожалуйста, оформляйте ваш код и выводы аккуратно, при необходимости добавляйте секции и форматируйте текст.

```
from google.colab import files
uploaded = files.upload()
import pandas as pd
movie = pd.read_csv('netflix_titles.csv')
movie.shape
```

Выбрать файлы netflix_titles.csv
netflix_titles.csv(text/csv) - 3399671 bytes, last modified: 07.03.2026 - 100% done
 Saving netflix_titles.csv to netflix_titles.csv
 (8807, 12)

```
movie.head()
```

	show_id	type	title	director	cast	country	date_added	release_year	rating	duration	listed_in	descript
0	s1	Movie	Dick Johnson Is Dead	Kirsten Johnson	NaN	United States	September 25, 2021	2020	PG-13	90 min	Documentaries	As her fa near: end c life, film
1	s2	TV Show	Blood & Water	NaN	Ama Qamata, Khosi Ngema, Gail Mabalane, Thaban...	South Africa	September 24, 2021	2021	TV-MA	2 Seasons	International TV Shows, TV Dramas, TV Mysteries	cross paths party, a C Tow
2	s3	TV Show	Ganglands	Julien Leclercq	Sami Bouajila, Tracy Gotoas, Samuel	NaN	September 24, 2021	2021	TV-MA	1 Season	Crime TV Shows, International TV Shows, TV	To protec family fro pow drea

При выводе первых строк, можно заметить, что столбцы "director", "cast", "Country", содержат пропуски, других критических недочетов в датасете при анализе первых строк нет. Для начала заполним пропуски.

Текстовые категориальные признаки заполняются значением "Unknown", чтобы не удалять строки и сохранить информацию о фильмах. Для категориальных признаков типа rating используется наиболее частое значение (mode).

```
movie['director'] = movie['director'].fillna('Unknown')
movie['cast'] = movie['cast'].fillna('Unknown')
movie['country'] = movie['country'].fillna('Unknown')
movie['rating'] = movie['rating'].fillna(movie['rating'].mode()[0])
```

Напишите программный код или [сгенерируйте](#) его с помощью искусственного интеллекта.

УДОСТОВЕРЬТЕСЬ, ЧТО ВСЕ ВАШИ ВЫВОДЫ И КОД ОФОРМЛЕНЫ ТАК, ЧТОБЫ ЛЕГКО МОЖНО БЫЛО ПОНЯТЬ, К ЧЕМУ ОНИ ОТНОСЯТСЯ

НЕ ЗАБУДЬТЕ ПЕРЕЗАПУСТИТЬ НОУТБУК ТАК, ЧТОБЫ ВСЕ ЯЧЕЙКИ БЫЛИ ЗАПУЩЕНЫ ПОДРЯД, НАЧИНАЯ С [1]

Не удается связаться с сервисом reCAPTCHA. Проверьте подключение к Интернету и перезагрузите страницу.